Práctica— Análisis Descriptivo de Datos

Business Analytics

Campo	Detalle
Estudiante	Jeison Fabian Malagon Benavides
Programa	Especialización en Analítica y Ciencia de Datos, Universidad de Cundinamarca

Preparación del entorno

Se importan las librerías: **pandas** y **numpy** para manipular y calcular, y **matplotlib** y **seaborn** para las visualizaciones. Se define un formato común de gráficos y una función para mostrar valores monetarios en millones de pesos (COP).

```
import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as mtick
import seaborn as sns

sns.set_theme(style="whitegrid", context="notebook")
plt.rcParams.update({"figure.dpi": 110, "axes.titleweight": "bold", "axes.titlesize": 12, "axes.labelsize": 10})
pd.options.display.float_format = "{:,.2f}".format
pd.set_option("display.max_columns", None)

AZUL, NARANJA, GRIS = "#2E74B5", "#E8A33D", "#7F7F7F"

def millones(x, pos=None):
    """Formatea un valor en pesos como millones: 1500000 -> '$2 M'."""
    return f"${x/1e6:,.1f} M" if abs(x) < 1e6 else f"${x/1e6:,.0f} M"

print("Librerías cargadas correctamente.")
```

```
Librerías cargadas correctamente.
```

Carga y exploración de los datos

Paso 1. Se carga. El archivo `ventas.csv`

```
RUTA_ARCHIVO = "ventas.csv"

if not os.path.exists(RUTA_ARCHIVO):
    try:
        from google.colab import files
        print("Archivo no encontrado en el repositorio. Sube 'ventas_ejemplo.csv' manualmente:")
        subido = files.upload()
        RUTA_ARCHIVO = list(subido.keys())[0]
    except ImportError:
        raise FileNotFoundError("No se encontró 'ventas_ejemplo.csv'. Colócalo en la misma carpeta que este notebook.")

df_raw = pd.read_csv(RUTA_ARCHIVO)
print(f"Datos cargados: {df_raw.shape[0]} filas x {df_raw.shape[1]} columnas.")
df_raw.head(10)
```

```
Datos cargados: 426 filas x 6 columnas.
```

	Fecha	Region	Producto	Vendedor	Unidades	PrecioUnitario
0	2026-06-01	Bogotá	Webcam	Luis Peña	3.00	95000
1	2026-01-15	Barranquilla	Webcam	Luis Peña	2.00	115000
2	2025-06-23	Cali	Mouse	Diana Gómez	3.00	60000
3	2026-04-16	Barranquilla	Monitor	Ana Torres	3.00	660000
4	2025-10-24	Cali	Webcam	Ana Torres	8.00	85000
5	2026-04-01	Bucaramanga	Impresora	Diana Gómez	15.00	500000
6	2025-10-23	Medellín	Mouse	Ana Torres	3.00	50000
7	2026-06-23	Barranquilla	Teclado	Sofía Reyes	9.00	120000
8	2025-12-13	Cali	Monitor	Sofía Reyes	9.00	640000
9	2025-12-08	Bogotá	Mouse	Diana Gómez	4.00	50000

Próximos pasos: Generar código con df_raw | New interactive sheet

Paso 2. Exploración inicial. Antes de analizar se revisa la estructura: tipos de dato, valores nulos, filas duplicadas, valores atípicos evidentes y categorías de las variables de texto. Esta revisión justifica las decisiones de limpieza del siguiente apartado.

```
print("Estructura del conjunto de datos:")
df_raw.info()

print("\nValores nulos por columna:")
print(df_raw.isnull().sum())

print(f"\nFilas duplicadas exactas: {df_raw.duplicated().sum()}")
print(f"Precios unitarios negativos: {(df_raw['PrecioUnitario'] < 0).sum()}")
print(f"Rango de fechas (texto): {df_raw['Fecha'].min()}  a  {df_raw['Fecha'].max()}")

print("\nCategorías en 'Region' (nótense las inconsistencias de mayúsculas y espacios):")
print(sorted(df_raw["Region"].unique()))
print("\nCategorías en 'Vendedor':")
print(sorted(df_raw["Vendedor"].unique()))
print("\nCategorías en 'Producto':")
print(sorted(df_raw["Producto"].unique()))
```

```
Estructura del conjunto de datos:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 426 entries, 0 to 425
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Fecha           426 non-null    object
 1   Region          426 non-null    object
 2   Producto        426 non-null    object
 3   Vendedor        426 non-null    object
 4   Unidades        420 non-null    float64
 5   PrecioUnitario  426 non-null    int64
dtypes: float64(1), int64(1), object(4)
memory usage: 20.1+ KB

Valores nulos por columna:
Fecha             0
Region            0
Producto          0
Vendedor          0
Unidades          6
PrecioUnitario    0
dtype: int64

Filas duplicadas exactas: 6
Precios unitarios negativos: 4
Rango de fechas (texto): 2025-01-02  a  2026-06-28

Categorías en 'Region' (nótense las inconsistencias de mayúsculas y espacios):
['  barranquilla  ', '  bucaramanga  ', '  medellín  ', '  pereira  ', 'BARRANQUILLA', 'BOGOTÁ', 'BUCARAMANGA', 'Barranquill

Categorías en 'Vendedor':
['Ana Torres', 'Ana Torres ', 'Carlos Ruiz', 'Diana Gómez', 'Jorge Salas', 'Jorge Salas ', 'Luis Peña', 'Sofía Reyes', 'Sofí

Categorías en 'Producto':
['Audífonos', 'Impresora', 'Laptop', 'Monitor', 'Mouse', 'Teclado', 'Webcam']
```

Diagnóstico de la exploración

Hallazgo	Evidencia	Implicación
Filas duplicadas	6 registros repetidos	Inflarían las ventas: se eliminan
Nulos en `Unidades`	6 registros sin cantidad	Sin cantidad no se puede calcular el ingreso: se eliminan (1,4 % de los datos)
Precios negativos	4 registros	Error de captura de signo: se corrigen con el valor absoluto
Texto inconsistente	Mayúsculas y espacios en `Region`, `Vendedor` y `Producto`	Una misma categoría aparecería varias veces: se estandariza
`Fecha` como texto	No es de tipo fecha	Se convierte para analizar el tiempo

Son las mismas decisiones documentadas en el taller de obtención de datos (ETL); aquí se aplican de nuevo para que el análisis parta de datos confiables y el notebook sea reproducible.

Limpieza y organización de los datos

Se aplican, en orden, las transformaciones del diagnóstico y se crean variables derivadas que facilitan el análisis:

- `Anio`, `Mes`, `Trimestre` y `Periodo` (año-mes) para análisis temporales.
- `VentaTotal` = `Unidades` × `PrecioUnitario`, el ingreso de cada transacción.

```
df = df_raw.copy()

# 1) Eliminar duplicados exactos
antes = len(df)
df = df.drop_duplicates()
print(f"Duplicados eliminados: {antes - len(df)}")

# 2) Estandarizar texto: sin espacios sobrantes y en formato 'Título'
for col in ["Region", "Vendedor", "Producto"]:
    df[col] = df[col].astype(str).str.strip().str.title()

# 3) Convertir 'Fecha' a datetime y derivar variables de tiempo
df["Fecha"] = pd.to_datetime(df["Fecha"], errors="coerce")
df["Anio"] = df["Fecha"].dt.year
df["Mes"] = df["Fecha"].dt.month
df["Trimestre"] = df["Fecha"].dt.to_period("Q").astype(str)
df["Periodo"] = df["Fecha"].dt.to_period("M").astype(str)

# 4) Eliminar filas sin 'Unidades' (1,4 % de los datos)
antes = len(df)
df = df.dropna(subset=["Unidades"])
df["Unidades"] = df["Unidades"].astype(int)
print(f"Filas eliminadas por 'Unidades' nula: {antes - len(df)}")

# 5) Corregir precios negativos (error de signo)
print(f"Precios negativos corregidos: {(df['PrecioUnitario'] < 0).sum()}")
df["PrecioUnitario"] = df["PrecioUnitario"].abs()

# 6) Ingreso por transacción
df["VentaTotal"] = df["Unidades"] * df["PrecioUnitario"]

df = df[["Fecha", "Anio", "Mes", "Trimestre", "Periodo", "Region", "Producto", "Vendedor", "Unidades", "PrecioUnitario", "Ve
df = df.sort_values("Fecha").reset_index(drop=True)
print(f"\nLimpieza completada: {df.shape[0]} filas x {df.shape[1]} columnas.")
df.head(8)
```

```
Duplicados eliminados: 6
Filas eliminadas por 'Unidades' nula: 6
Precios negativos corregidos: 4

Limpieza completada: 414 filas x 11 columnas.
```

	Fecha	Anio	Mes	Trimestre	Periodo	Region	Producto	Vendedor	Unidades	PrecioUnitario	VentaTotal
0	2025-01-02	2025	1	2025Q1	2025-01	Barranquilla	Mouse	Luis Peña	11	50000	550000
1	2025-01-03	2025	1	2025Q1	2025-01	Barranquilla	Audífonos	Carlos Ruiz	14	160000	2240000
2	2025-01-05	2025	1	2025Q1	2025-01	Bucaramanga	Webcam	Jorge Salas	13	105000	1365000
3	2025-01-08	2025	1	2025Q1	2025-01	Bogotá	Monitor	Sofía Reyes	3	650000	1950000
4	2025-01-09	2025	1	2025Q1	2025-01	Cali	Audífonos	Jorge Salas	4	140000	560000

Próximos pasos: Generar código con df | New interactive sheet

Validación posterior a la limpieza. Se comprueba que los problemas detectados ya no existen y se compara el antes y el después.

```
validacion = pd.DataFrame({
    "Antes (crudo)": [len(df_raw), df_raw.isnull().sum().sum(), df_raw.duplicated().sum(), (df_raw["PrecioUnitario"] < 0).su
    "Después (limpio)": [len(df), df.isnull().sum().sum(), df.duplicated().sum(), (df["PrecioUnitario"] < 0).sum(), df["Regi
}, index=["Filas", "Valores nulos", "Duplicados", "Precios negativos", "Regiones distintas"])
display(validacion)

print("Regiones:", sorted(df["Region"].unique()))
print("Productos:", sorted(df["Producto"].unique()))
print("Vendedores:", sorted(df["Vendedor"].unique()))
print(f"Periodo analizado: {df['Fecha'].min().date()} a {df['Fecha'].max().date()}")

# Se guarda el conjunto limpio como insumo reutilizable
df.to_csv("ventas_limpias.csv", index=False)
```

	Antes (crudo)	Después (limpio)
Filas	426	414
Valores nulos	6	0
Duplicados	6	0
Precios negativos	4	0
Regiones distintas	16	6

```
Regiones: ['Barranquilla', 'Bogotá', 'Bucaramanga', 'Cali', 'Medellín', 'Pereira']
Productos: ['Audífonos', 'Impresora', 'Laptop', 'Monitor', 'Mouse', 'Teclado', 'Webcam']
Vendedores: ['Ana Torres', 'Carlos Ruiz', 'Diana Gómez', 'Jorge Salas', 'Luis Peña', 'Sofía Reyes']
Periodo analizado: 2025-01-02 a 2026-06-28
```

Próximos pasos: Generar código con `validacion` | New interactive sheet

La limpieza dejó **414 transacciones** sin nulos ni duplicados, y **6 regiones** (en lugar de las variantes de escritura del archivo crudo). El análisis siguiente usa este conjunto.

Estadísticas descriptivas

Variables numéricas: tendencia central, dispersión y forma

Para `Unidades`, `PrecioUnitario` y `VentaTotal` se calcula un resumen completo. El **coeficiente de variación** (desviación estándar ÷ media) permite comparar la dispersión de variables con escalas distintas; la **asimetría** indica si hay cola hacia valores altos (positiva) o bajos (negativa), y la **curtosis**, si la distribución es más plana o más puntiaguda que la normal.

```
def resumen_numerico(s):
    return pd.Series({
        "Conteo": s.count(), "Media": s.mean(), "Mediana": s.median(), "Moda": s.mode().iloc[0],
        "Desviación estándar": s.std(), "Coeficiente de variación": s.std() / s.mean(),
        "Mínimo": s.min(), "Q1 (25 %)": s.quantile(0.25), "Q3 (75 %)": s.quantile(0.75), "Máximo": s.max(),
        "Rango": s.max() - s.min(), "IQR": s.quantile(0.75) - s.quantile(0.25),
        "Asimetría": s.skew(), "Curtosis": s.kurt(),
    })

tabla_num = df[["Unidades", "PrecioUnitario", "VentaTotal"]].apply(resumen_numerico)
tabla_num
```

	Unidades	PrecioUnitario	VentaTotal
Conteo	414.00	414.00	414.00
Media	7.57	622,234.30	4,631,292.27
Mediana	7.00	150,000.00	1,335,000.00
Moda	2.00	150,000.00	240,000.00
Desviación estándar	4.21	915,294.66	7,998,585.43
Coeficiente de variación	0.56	1.47	1.73
Mínimo	1.00	50,000.00	80,000.00
Q1 (25 %)	4.00	110,000.00	600,000.00
Q3 (75 %)	11.00	647,500.00	5,090,000.00
Máximo	15.00	2,820,000.00	42,000,000.00
Rango	14.00	2,770,000.00	41,920,000.00
IQR	7.00	537,500.00	4,490,000.00
Asimetría	0.17	1.85	2.77
Curtosis	-1.13	1.74	7.43

Próximos pasos: Generar código con `tabla_num` New interactive sheet

Interpretación

- `Unidades` (media 7,6; mediana 7; desviación 4,2; mínimo 1 y máximo 15): cada transacción vende pocas unidades y la distribución es casi simétrica (asimetría 0,17) y plana (curtosis −1,13): los pedidos de 1 a 15 unidades son casi igual de frecuentes. Es una variable estable, sin valores extremos.
- `PrecioUnitario` (media $622.234, mediana$150.000; desviación $915.295; coeficientedevariación1, 47) : lamediaesmásdecuatroveceslamediana. Noesunaanomalía : elcatálogomezclaartículosde$ 50.000 (mouse) y de $2.820.000(laptop), demodoqueelpreciodependedelproducto, nodelatransacción. − ∗ ∗‘VentaTotal‘∗ ∗ (media$ 4.631.292, mediana $1.335.000; desviación$7.998.585; coeficiente de variación 1,73; asimetría 2,77; curtosis 7,43; máximo $42.000.000): es la variable más dispersa y con cola larga a la derecha. **El ingreso típico (mediana) es mucho menor que el ingreso promedio**: pocas transacciones muy grandes elevan la media. Por eso, para describir una venta "normal" conviene usar la mediana.

```
# Transacciones atípicas por la regla del rango intercuartílico (IQR)
q1, q3 = df["VentaTotal"].quantile([0.25, 0.75])
umbral = q3 + 1.5 * (q3 - q1)
atipicas = df[df["VentaTotal"] > umbral]

print(f"Umbral de atípicos (Q3 + 1,5·IQR): ${umbral:,.0f}")
print(f"Transacciones atípicas: {len(atipicas)} de {len(df)} ({len(atipicas)/len(df):.1%})")
print(f"Participación de las atípicas en el ingreso total: {atipicas['VentaTotal'].sum()/df['VentaTotal'].sum():.1%}")
print("Productos de las transacciones atípicas:")
print(atipicas["Producto"].value_counts())
```

```
Umbral de atípicos (Q3 + 1,5·IQR): $11,825,000
Transacciones atípicas: 42 de 414 (10.1%)
Participación de las atípicas en el ingreso total: 56.8%
Productos de las transacciones atípicas:
Producto
Laptop    42
Name: count, dtype: int64
```

Lectura. Las 42 transacciones atípicas (10,1 % del total) son **todas ventas de laptops** y generan el 56,8 % de los ingresos. No son errores de captura: son ventas legítimas de un producto de alto valor, y deben conservarse.

Variables categóricas: tablas de frecuencia

Se cuenta cuántas transacciones hay por producto, región y vendedor, y qué porcentaje del total representa cada una.

```
def frecuencia(col):
    t = df[col].value_counts().to_frame("Transacciones")
    t["% del total"] = 100 * t["Transacciones"] / t["Transacciones"].sum()
    return t
```

```
for col in ["Producto", "Region", "Vendedor"]:
    print(f"\nFrecuencia por {col}")
    display(frecuencia(col))
```

```
Frecuencia por Producto
```

Producto	Transacciones	% del total
Audífonos	70	16.91
Webcam	65	15.70
Monitor	61	14.73
Laptop	59	14.25
Mouse	57	13.77
Impresora	51	12.32
Teclado	51	12.32

```
Frecuencia por Region
```

Region	Transacciones	% del total
Cali	79	19.08
Barranquilla	72	17.39
Pereira	72	17.39
Bucaramanga	71	17.15
Medellín	64	15.46
Bogotá	56	13.53

```
Frecuencia por Vendedor
```

Vendedor	Transacciones	% del total
Sofía Reyes	79	19.08
Luis Peña	76	18.36
Diana Gómez	72	17.39
Jorge Salas	69	16.67
Ana Torres	60	14.49
Carlos Ruiz	58	14.01

Interpretación. En número de transacciones el reparto es **parejo**: cada producto concentra entre 12,3 % y 16,9 % de las transacciones; entre regiones, Cali (79) y Bogotá (56) son los extremos; entre vendedores, Sofía Reyes (79) y Carlos Ruiz (58). Más adelante se verá que **el volumen de transacciones no coincide con el valor vendido**.

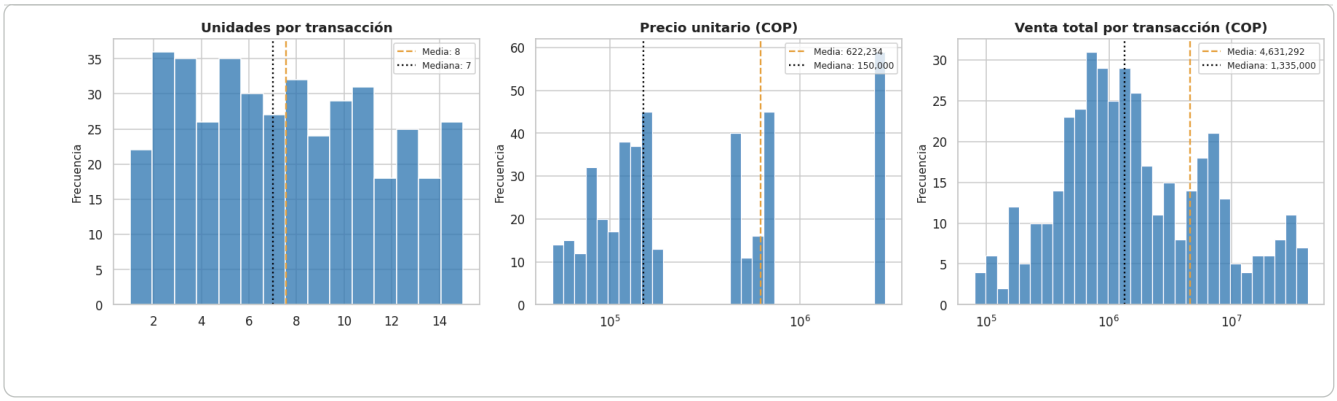
Distribución de las variables

Los histogramas muestran la forma de cada distribución; las líneas verticales marcan la media y la mediana. Para `VentaTotal` se usa escala logarítmica en el eje horizontal por su cola larga.

```
fig, ejes = plt.subplots(1, 3, figsize=(16, 4.2))

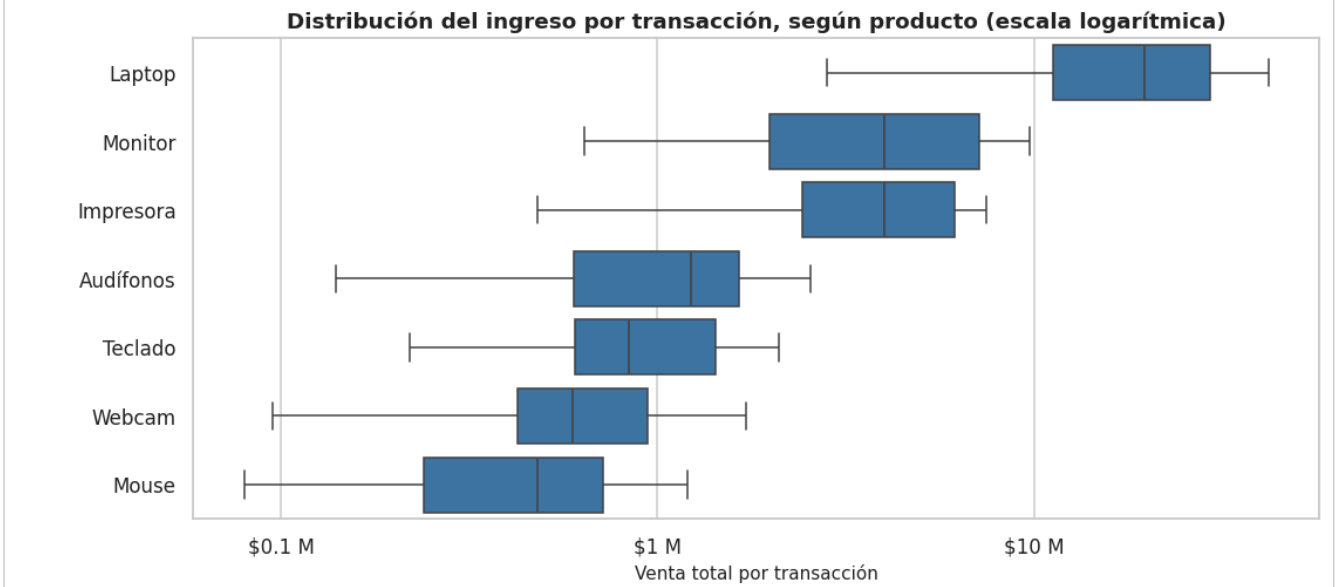
for ax, col, titulo in zip(ejes, ["Unidades", "PrecioUnitario", "VentaTotal"], ["Unidades por transacción", "Precio unitario
    if col == "Unidades":
        sns.histplot(df[col], bins=15, color=AZUL, ax=ax)
    else:
        sns.histplot(df[col], bins=30, color=AZUL, ax=ax, log_scale=True)
    ax.axvline(df[col].mean(), color=NARANJA, linestyle="--", label=f"Media: {df[col].mean():,.0f}")
    ax.axvline(df[col].median(), color="black", linestyle=":", label=f"Mediana: {df[col].median():,.0f}")
    ax.set_title(titulo); ax.set_xlabel(""); ax.set_ylabel("Frecuencia"); ax.legend(fontsize=8)

plt.tight_layout(); plt.show()
```



Interpretación. `Unidades` tiene forma casi uniforme. `PrecioUnitario` y `VentaTotal` muestran **varias concentraciones** (picos), reflejo de que cada producto tiene su propio rango de precio. La media (línea naranja) queda por encima de la mediana (línea negra) en ambas, señal de cola a la derecha.

```
# Dispersión del ingreso por producto
orden = df.groupby("Producto")["VentaTotal"].median().sort_values(ascending=False).index
plt.figure(figsize=(10, 4.8))
sns.boxplot(data=df, y="Producto", x="VentaTotal", order=orden, color=AZUL, fliersize=3)
plt.xscale("log")
plt.gca().xaxis.set_major_formatter(mtick.FuncFormatter(millones))
plt.title("Distribución del ingreso por transacción, según producto (escala logarítmica)")
plt.xlabel("Venta total por transacción"); plt.ylabel("")
plt.tight_layout(); plt.show()
```



Interpretación. El diagrama de caja confirma que el producto explica el nivel de ingreso: las transacciones de **laptop** están en una franja muy por encima de las demás, mientras que mouse, teclado y webcam se concentran en ingresos bajos. Dentro de cada producto la dispersión es moderada: lo que cambia es la cantidad de unidades por transacción.

Análisis por dimensiones del negocio

Se calculan para cada grupo: transacciones, unidades, ventas totales, **ticket promedio** (ingreso medio por transacción) y **participación** en las ventas.

```
def resumen_dimension(col):
    g = df.groupby(col).agg(Transacciones=("VentaTotal", "size"), Unidades=("Unidades", "sum"),
                            VentaTotal=("VentaTotal", "sum"), TicketPromedio=("VentaTotal", "mean"))
    g["Participación %"] = 100 * g["VentaTotal"] / g["VentaTotal"].sum()
    return g.sort_values("VentaTotal", ascending=False)

print(f"Ventas totales del periodo: ${df['VentaTotal'].sum():,.0f}  |  Transacciones: {len(df)}  |  Ticket promedio: ${df['V
```

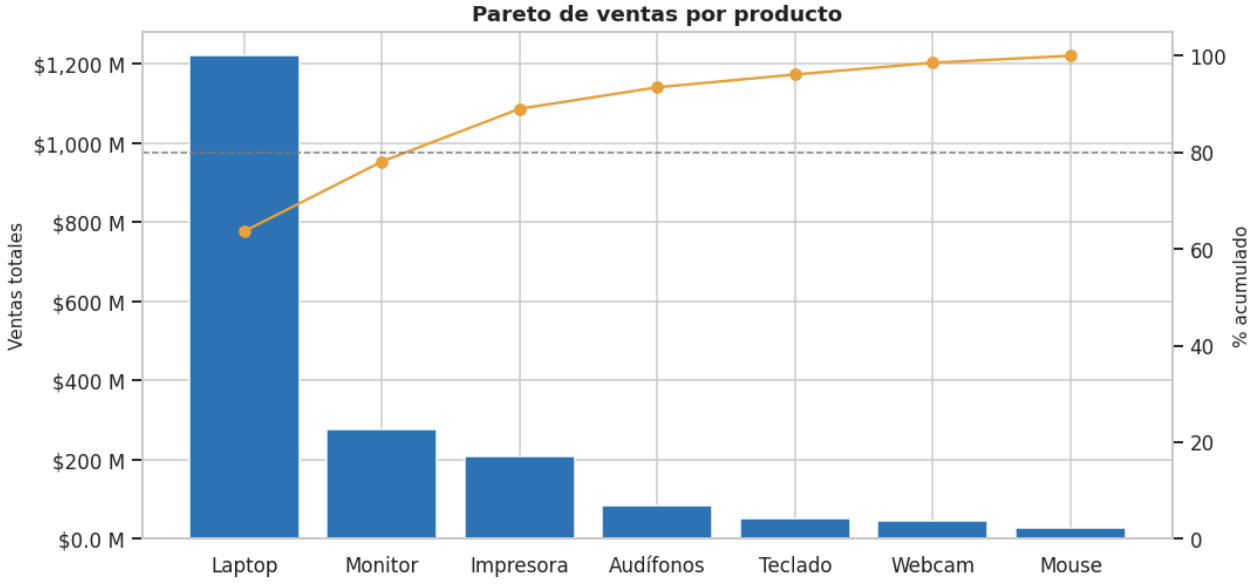
```
Ventas totales del periodo: $1,917,355,000  |  Transacciones: 414  |  Ticket promedio: $4,631,292
```

Ventas por producto y diagrama de Pareto

```
prod = resumen_dimension("Producto")
prod["Acumulado %"] = prod["Participación %"].cumsum()
display(prod)

fig, ax = plt.subplots(figsize=(10, 4.8))
ax.bar(prod.index, prod["VentaTotal"], color=AZUL)
ax.yaxis.set_major_formatter(mtick.FuncFormatter(millones)); ax.set_ylabel("Ventas totales")
ax2 = ax.twinx()
ax2.plot(prod.index, prod["Acumulado %"], color=NARANJA, marker="o")
ax2.axhline(80, color=GRIS, linestyle="--", linewidth=1); ax2.set_ylim(0, 105); ax2.set_ylabel("% acumulado"); ax2.grid(Fa
ax.set_title("Pareto de ventas por producto"); plt.tight_layout(); plt.show()
```

Producto	Transacciones	Unidades	VentaTotal	TicketPromedio	Participación %	Acumulado %
Laptop	59	435	1220920000	20,693,559.32	63.68	63.68
Monitor	61	424	276810000	4,537,868.85	14.44	78.11
Impresora	51	432	209350000	4,104,901.96	10.92	89.03
Audífonos	70	550	85200000	1,217,142.86	4.44	93.48
Teclado	51	401	50820000	996,470.59	2.65	96.13
Webcam	65	463	46475000	715,000.00	2.42	98.55
Mouse	57	428	27780000	487,368.42	1.45	100.00



Próximos pasos: Generar código con prod | New interactive sheet

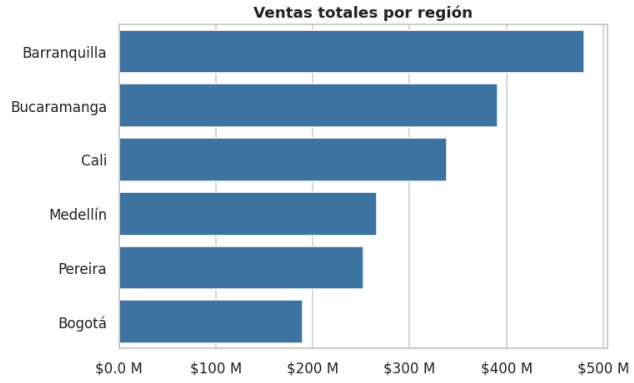
Interpretación. Laptop concentra el 63,7 % de los ingresos ($1.220,9 millones) con solo el 14,3 % de las transacciones. Tres productos (laptop, monitor e impresora) suman el **89 %** de las ventas, mientras que mouse, teclado y webcam aportan juntos apenas el 6,5 %. Hay una fuerte dependencia de un solo producto: el comportamiento de las laptops determina el resultado de la empresa.

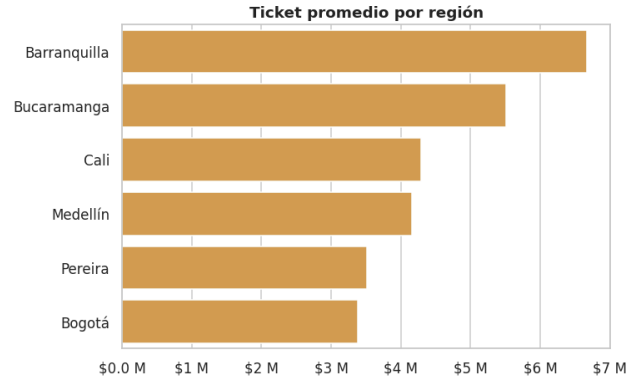
Ventas por región

```
reg = resumen_dimension("Region")
display(reg)

fig, ejes = plt.subplots(1, 2, figsize=(14, 4.4))
sns.barplot(x=reg["VentaTotal"], y=reg.index, color=AZUL, ax=ejes[0])
ejes[0].xaxis.set_major_formatter(mtick.FuncFormatter(millones)); ejes[0].set_title("Ventas totales por región"); ejes[0].s
sns.barplot(x=reg["TicketPromedio"], y=reg.index, color=NARANJA, ax=ejes[1])
ejes[1].xaxis.set_major_formatter(mtick.FuncFormatter(millones)); ejes[1].set_title("Ticket promedio por región"); ejes[1]
plt.tight_layout(); plt.show()
```

Region	Transacciones	Unidades	VentaTotal	TicketPromedio	Participación %
Barranquilla	72	596	480365000	6,671,736.11	25.05
Bucaramanga	71	569	390675000	5,502,464.79	20.38
Cali	79	557	338520000	4,285,063.29	17.66
Medellín	64	483	265825000	4,153,515.62	13.86
Pereira	72	556	252635000	3,508,819.44	13.18
Bogotá	56	372	189335000	3,380,982.14	9.87





Próximos pasos: Generar código con reg | New interactive sheet

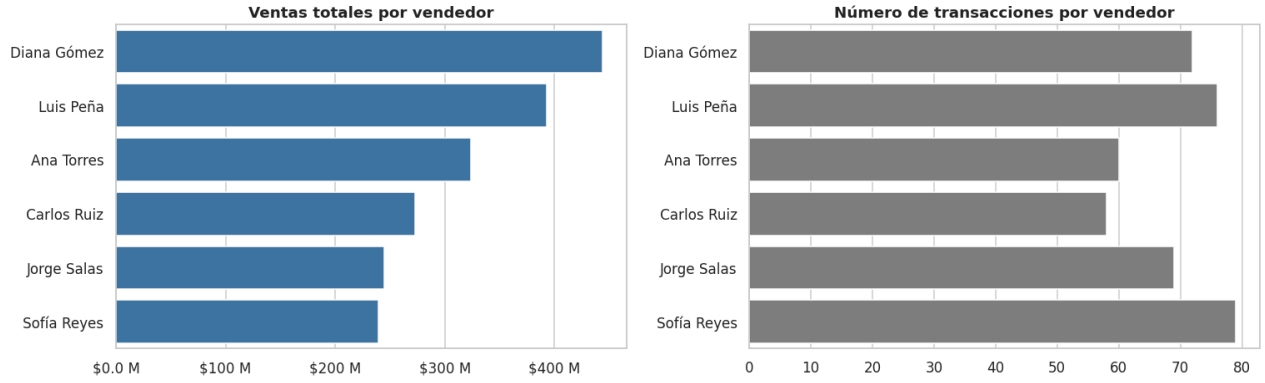
Interpretación. Barranquilla lidera con $480,4 millones$ (25, 1189,3 millones; 9,9 %), con menos transacciones (56) y el ticket promedio más bajo ($3,38 millones$). $La diferencia entre regiones se explica sobre todo por las laptops: en Barranquilla suman$ 351,2 millones (73,1 % de su venta), frente a $109,5 millones en Bogotá.

Ventas por vendedor

```
ven = resumen_dimension("Vendedor")
display(ven)

fig, ejes = plt.subplots(1, 2, figsize=(14, 4.4))
sns.barplot(x=ven["VentaTotal"], y=ven.index, color=AZUL, ax=ejes[0])
ejes[0].xaxis.set_major_formatter(mtick.FuncFormatter(millones)); ejes[0].set_title("Ventas totales por vendedor"); ejes[0]
sns.barplot(x=ven["Transacciones"], y=ven.index, color=GRIS, ax=ejes[1])
ejes[1].set_title("Número de transacciones por vendedor"); ejes[1].set_xlabel(""); ejes[1].set_ylabel("")
plt.tight_layout(); plt.show()
```

Vendedor	Transacciones	Unidades	VentaTotal	TicketPromedio	Participación %
Diana Gómez	72	553	444030000	6,167,083.33	23.16
Luis Peña	76	627	392660000	5,166,578.95	20.48
Ana Torres	60	449	323975000	5,399,583.33	16.90
Carlos Ruiz	58	446	272615000	4,700,258.62	14.22
Jorge Salas	69	545	244830000	3,548,260.87	12.77
Sofía Reyes	79	513	239245000	3,028,417.72	12.48



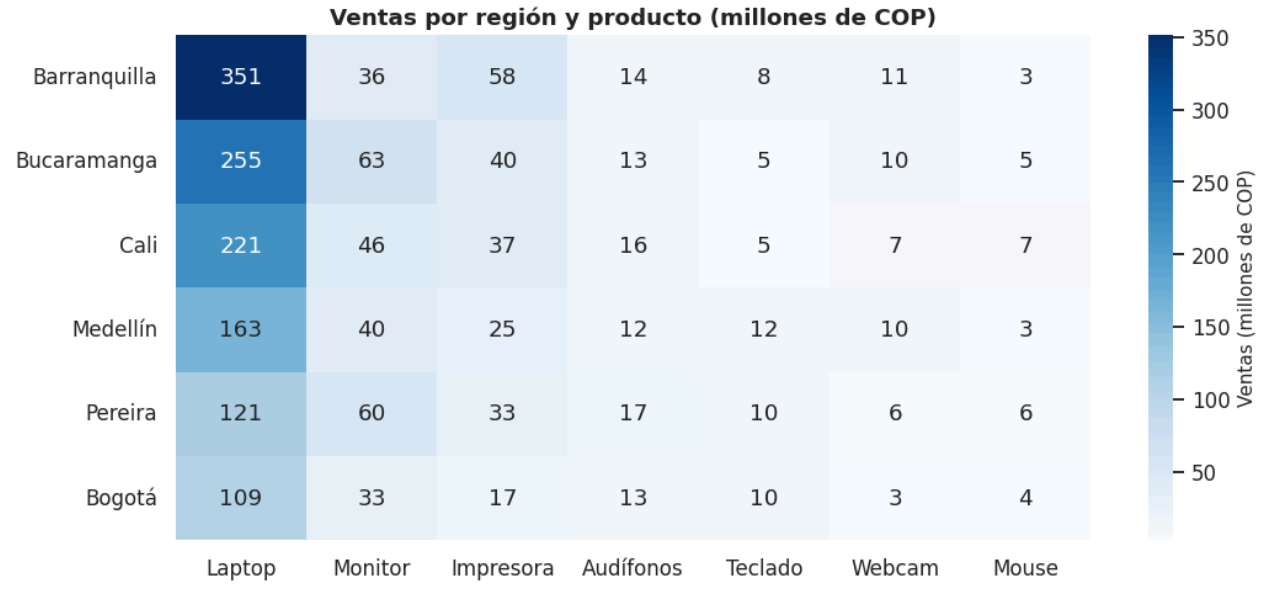
Próximos pasos: Generar código con ven | New interactive sheet

Interpretación. Diana Gómez lidera en ingresos ($444,0 millones$; $23,26$,17 millones: el 73,3 % de lo que vende son laptops. **Sofía Reyes** realiza más transacciones (79) pero tiene el ticket más bajo ($3,03 millones) y es la última en ingresos (12,5 %): vende mucho volumen de productos de menor valor. Cuántas ventas se cierran no equivale a cuánto se factura.

Cruce región × producto

```
cruce = df.pivot_table(index="Region", columns="Producto", values="VentaTotal", aggfunc="sum", fill_value=0) / 1e6
cruce = cruce.loc[reg.index, prod.index]

plt.figure(figsize=(10, 4.6))
sns.heatmap(cruce, annot=True, fmt=",.0f", cmap="Blues", cbar_kws={"label": "Ventas (millones de COP)"})
plt.title("Ventas por región y producto (millones de COP)"); plt.xlabel(""); plt.ylabel("")
plt.tight_layout(); plt.show()
```



Interpretación. El mapa de calor muestra que la columna de **laptop** domina en todas las regiones. La brecha de Bogotá frente a Barranquilla se concentra en **laptops** ($109,5 frente a 351$,2 millones) e **impresoras** ($16,6 frente a 57$,5 millones), mientras que en

monitores vende casi lo mismo ($33,4 frente a$35,6 millones). Los accesorios (mouse, teclado, webcam y audífonos) aportan poco en todas las regiones, entre $2,6 y$16,9 millones por producto.

Tendencia en el tiempo

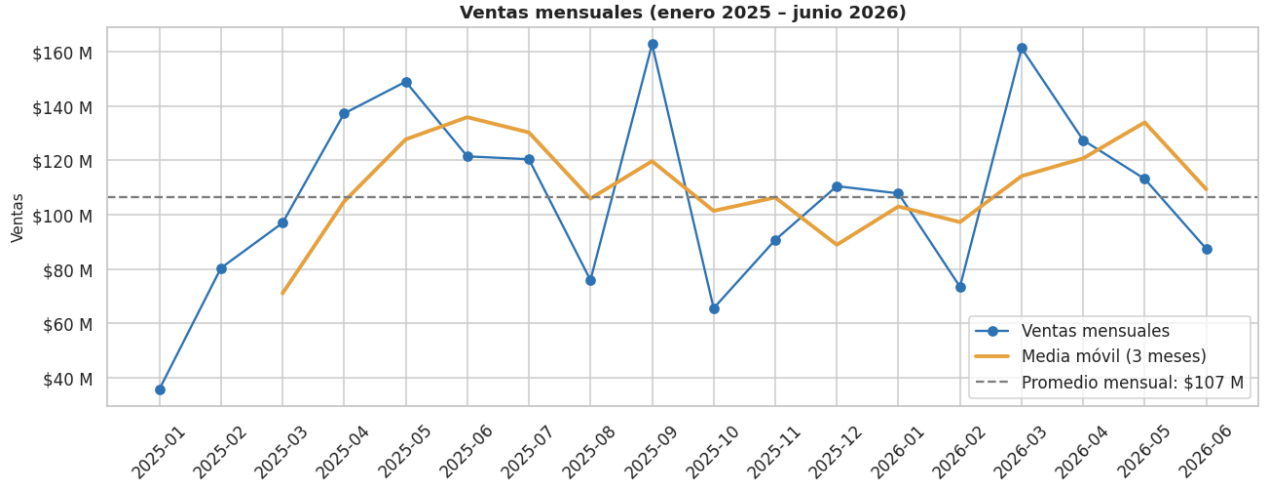
Ventas mensuales y media móvil

Se agrupan las ventas por mes y se calcula una **media móvil de 3 meses** para suavizar la variación y ver la tendencia de fondo.

```
mensual = df.groupby("Periodo")["VentaTotal"].sum().to_frame("VentaTotal")
mensual["Media móvil 3m"] = mensual["VentaTotal"].rolling(3).mean()
mensual["Variación mensual %"] = mensual["VentaTotal"].pct_change() * 100

fig, ax = plt.subplots(figsize=(12, 4.8))
ax.plot(mensual.index, mensual["VentaTotal"], marker="o", color=AZUL, label="Ventas mensuales")
ax.plot(mensual.index, mensual["Media móvil 3m"], color=NARANJA, linewidth=2.5, label="Media móvil (3 meses)")
ax.axhline(mensual["VentaTotal"].mean(), color=GRIS, linestyle="--", label=f"Promedio mensual: {millones(mensual['VentaTota
ax.yaxis.set_major_formatter(mtick.FuncFormatter(millones)); ax.set_title("Ventas mensuales (enero 2025 – junio 2026)")
ax.set_xlabel(""); ax.set_ylabel("Ventas"); plt.xticks(rotation=45); ax.legend()
plt.tight_layout(); plt.show()

print(f"Promedio mensual: ${mensual['VentaTotal'].mean():,.0f}  |  Desviación: ${mensual['VentaTotal'].std():,.0f}  |  Coef
print(f"Mes con mayores ventas: {mensual['VentaTotal'].idxmax()} (${mensual['VentaTotal'].max():,.0f})")
print(f"Mes con menores ventas: {mensual['VentaTotal'].idxmin()} (${mensual['VentaTotal'].min():,.0f})")
```



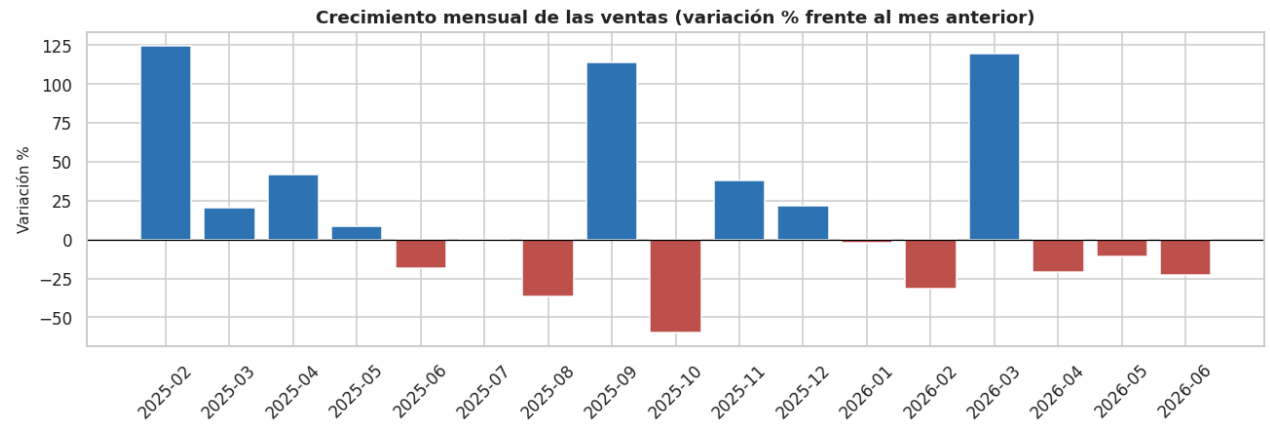

```
Promedio mensual: $106,519,722  |  Desviación: $34,191,182  |  Coef. de variación: 0.32
Mes con mayores ventas: 2025-09 ($162,675,000)
Mes con menores ventas: 2025-01 ($35,850,000)
```

Interpretación. Las ventas promedian **
$106,5 millones al mes **, pero oscilan bastante (coeficiente de variación 0,32). El mes más alto fue **septiembre de 2025 **(
162,7 millones) y el más bajo **enero de 2025** (
$35,9 millones). La media móvil muestra un aumento en el primer semestre de 2025 y, desde entonces, una *89 y $136 *meseta con fluctuaciones **(desde mediados de 2025 la media móvil se mueve entre
millones), sin una tendencia sostenida al alza en 2026.

Crecimiento mensual

```
fig, ax = plt.subplots(figsize=(12, 4.2))
valores = mensual["Variación mensual %"].dropna()
ax.bar(valores.index, valores, color=[AZUL if v >= 0 else "#C0504D" for v in valores])
ax.axhline(0, color="black", linewidth=0.8)
ax.set_title("Crecimiento mensual de las ventas (variación % frente al mes anterior)")
ax.set_ylabel("Variación %"); ax.set_xlabel(""); plt.xticks(rotation=45)
plt.tight_layout(); plt.show()

print(f"Meses con crecimiento: {(valores > 0).sum()}  |  Meses con caída: {(valores < 0).sum()}")
```




```
Meses con crecimiento: 8  |  Meses con caída: 9
```

Interpretación. El crecimiento mensual es **muy volátil**: hay aumentos superiores al 100 % (febrero y septiembre de 2025, marzo de 2026) y caídas de hasta −60 % (octubre de 2025). Oscilaciones de ese tamaño sugieren que el resultado de cada mes depende de pocas ventas grandes; el siguiente cálculo lo contrasta con las ventas de laptops.

```
laptop_mes = df[df["Producto"] == "Laptop"].groupby("Periodo")["VentaTotal"].sum().reindex(mensual.index).fillna(0)
print(f"Correlación entre las ventas mensuales totales y las ventas mensuales de laptops: {mensual['VentaTotal'].corr(laptc
print(f"Participación de las laptops en septiembre de 2025 (mes más alto): {laptop_mes['2025-09'] / mensual.loc['2025-09',
print(f"Participación de las laptops en enero de 2025 (mes más bajo): {laptop_mes['2025-01'] / mensual.loc['2025-01', 'Vent
```

```
Correlación entre las ventas mensuales totales y las ventas mensuales de laptops: 0.90
Participación de las laptops en septiembre de 2025 (mes más alto): 81.1%
Participación de las laptops en enero de 2025 (mes más bajo): 0.0%
```

Lectura. La correlación de 0,90 indica que **los meses buenos y malos dependen casi por completo de las ventas de laptops**: en septiembre de 2025 representaron el 81,1 % del mes y en enero de 2025, el mes más bajo, no hubo ninguna venta de laptops.

Comparación interanual del primer semestre (2025 frente a 2026)

Para comparar periodos equivalentes se usan los meses de enero a junio de ambos años.

```
semestre = df[df["Mes"] <= 6]
comp = semestre.pivot_table(index="Mes", columns="Anio", values="VentaTotal", aggfunc="sum") / 1e6

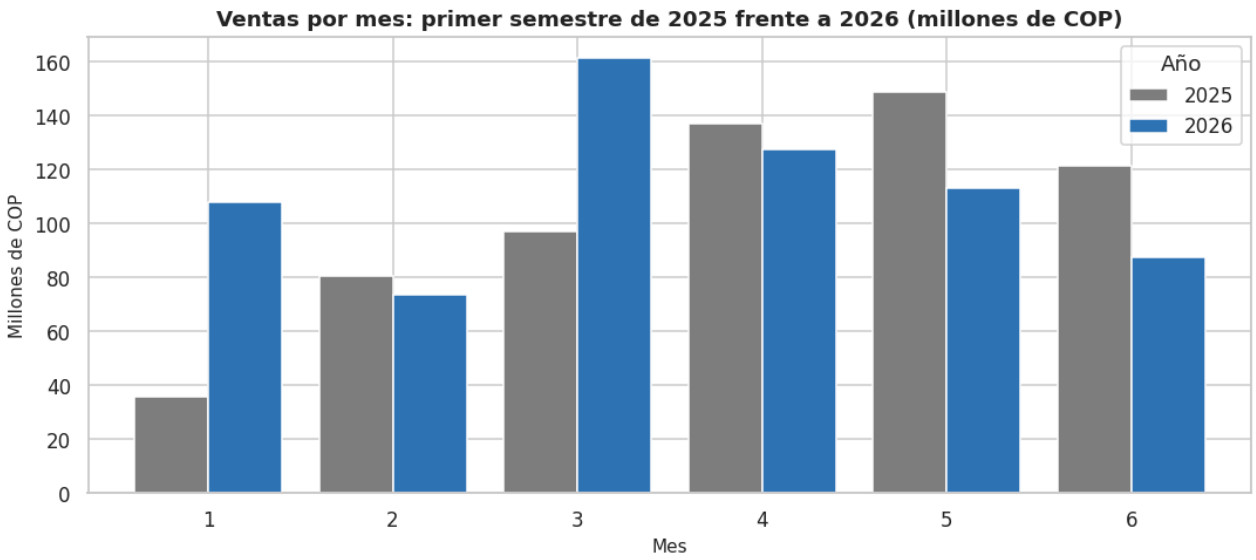
ax = comp.plot(kind="bar", figsize=(10, 4.6), color=[GRIS, AZUL], width=0.8)
ax.set_title("Ventas por mes: primer semestre de 2025 frente a 2026 (millones de COP)")
ax.set_xlabel("Mes"); ax.set_ylabel("Millones de COP"); plt.xticks(rotation=0); plt.legend(title="Año")
plt.tight_layout(); plt.show()

tot = comp.sum()
print(f"Primer semestre 2025: ${tot[2025]*1e6:,.0f}  |  Primer semestre 2026: ${tot[2026]*1e6:,.0f}  |  Variación: {(tot[202

print("\nComparación por trimestre (millones de COP):")
trim = semestre.assign(Trim=np.where(semestre["Mes"] <= 3, "T1 (ene-mar)", "T2 (abr-jun)")).pivot_table(index="Trim", column
trim["Variación %"] = (trim[2026] / trim[2025] - 1) * 100
display(trim)

print("\nVariación por producto (primer semestre):")
por_prod = semestre.pivot_table(index="Producto", columns="Anio", values="VentaTotal", aggfunc="sum") / 1e6
por_prod["Variación %"] = (por_prod[2026] / por_prod[2025] - 1) * 100
display(por_prod.sort_values("Variación %", ascending=False))

print("\nVariación por región (primer semestre):")
por_reg = semestre.pivot_table(index="Region", columns="Anio", values="VentaTotal", aggfunc="sum") / 1e6
por_reg["Variación %"] = (por_reg[2026] / por_reg[2025] - 1) * 100
display(por_reg.sort_values("Variación %", ascending=False))
```



Primer semestre 2025: $620,825,000 | Primer semestre 2026: $670,635,000 | Variación: +8.0%

Comparación por trimestre (millones de COP):

Trim	Anio 2025	2026	Variación %
T1 (ene-mar)	213.25	342.61	60.66
T2 (abr-jun)	407.58	328.03	-19.52

Variación por producto (primer semestre):

Producto	Anio 2025	2026	Variación %
Impresora	46.98	82.83	76.31
Laptop	390.58	429.20	9.89
Monitor	98.32	98.15	-0.17
Audífonos	34.59	26.79	-22.55
Webcam	17.54	12.47	-28.86
Mouse	12.12	8.45	-30.28
Teclado	20.70	12.74	-38.45

Variación por región (primer semestre):

Region	Anio 2025	2026	Variación %
Bogotá	50.66	88.25	74.22
Bucaramanga	107.21	139.08	29.73
Cali	98.92	123.09	24.44
Barranquilla	144.84	176.88	22.12
Medellín	112.61	110.05	-2.28
Pereira	106.58	33.28	-68.77

Próximos pasos: Generar código con `trim` New interactive sheet

Interpretación. El primer semestre de 2026 vendió $670,6 millones frente a $620,8 millones en 2025: un **crecimiento de 8,0 %**. Detrás de la cifra total hay movimientos opuestos:

- **Por trimestre:** el crecimiento se concentra en el **primer trimestre (+60,7 %)**; el **segundo trimestre de 2026 quedó 19,5 % por debajo** del de 2025, con caídas en abril, mayo y junio (el gráfico lo muestra: solo enero y marzo superan al año anterior).
- **Por producto:** crecieron la **impresora (+76,3 %)** y la **laptop (+9,9 %)**; el monitor se mantuvo (−0,2 %); y los accesorios **cayeron** (audífonos −22,5 %, webcam −28,9 %, mouse −30,3 % y teclado −38,5 %).
- **Por región:** crecieron Bogotá (+74,2 %), Bucaramanga (+29,7 %), Cali (+24,4 %) y Barranquilla (+22,1 %); Medellín se mantuvo (−2,3 %) y **Pereira cayó −68,8 %**, de $106,6 a 33,3 millones. Pereira merece una revisión específica.

Cambios de precio año contra año

```
precio = df.pivot_table(index="Producto", columns="Anio", values="PrecioUnitario", aggfunc="mean")
precio["Variación %"] = (precio[2026] / precio[2025] - 1) * 100
display(precio.sort_values("Variación %"))
```

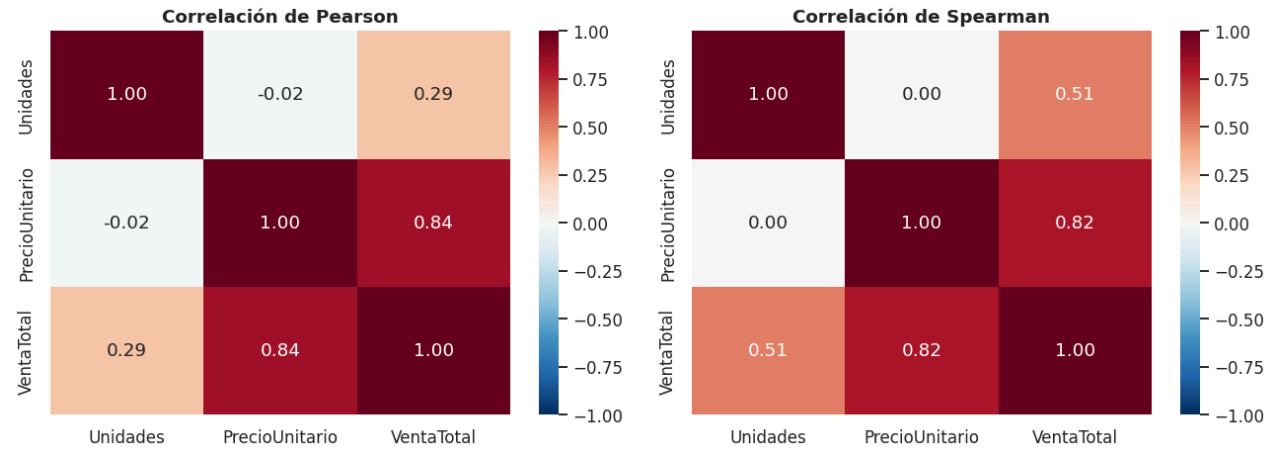
Anio Producto	2025	2026	Variación %
Webcam	100,333.33	99,000.00	-1.33
Audífonos	154,489.80	153,333.33	-0.75
Monitor	655,000.00	651,200.00	-0.58
Laptop	2,806,578.95	2,807,619.05	0.04
Impresora	483,448.28	485,909.09	0.51
Teclado	125,675.68	126,428.57	0.60
Mouse	65,116.28	65,714.29	0.92

Interpretación. Los precios promedio **prácticamente no cambian** de 2025 a 2026: las variaciones están entre −1,3 % (webcam) y +0,9 % (mouse), y la laptop se mantiene en torno a $2,8 millones. Por tanto, el crecimiento del semestre no se explica por cambios de precio, sino por el **volumen y la mezcla de productos vendidos**.

Relaciones entre variables

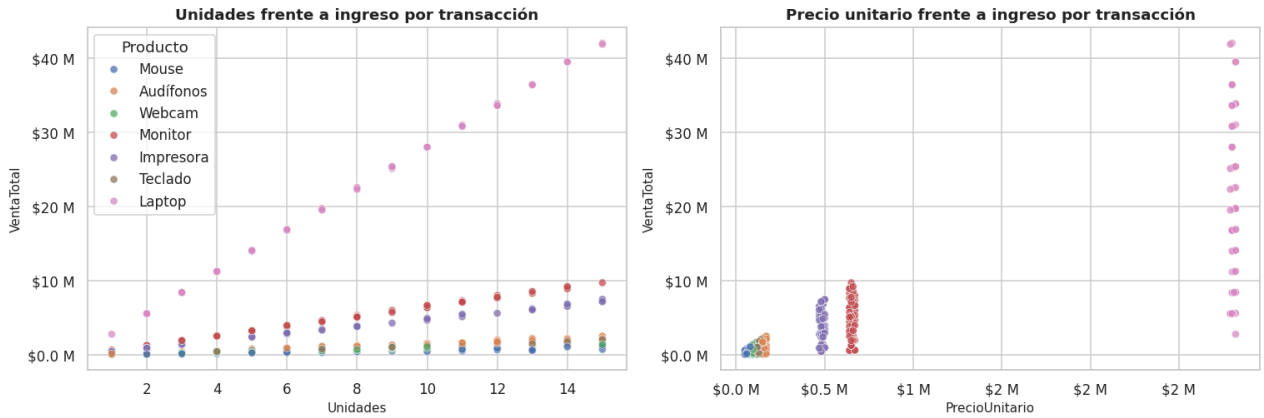
La **correlación de Pearson** mide la relación lineal entre dos variables (de −1 a 1); la de **Spearman**, la relación de orden, menos sensible a valores extremos. Se calculan ambas entre `Unidades`, `PrecioUnitario` y `VentaTotal`.

```
variables = ["Unidades", "PrecioUnitario", "VentaTotal"]
fig, ejes = plt.subplots(1, 2, figsize=(12, 4.4))
for ax, metodo in zip(ejes, ["pearson", "spearman"]):
    sns.heatmap(df[variables].corr(method=metodo), annot=True, fmt=".2f", cmap="RdBu_r", vmin=-1, vmax=1, ax=ax)
    ax.set_title(f"Correlación de {metodo.capitalize()}")
plt.tight_layout(); plt.show()
```




```
fig, ejes = plt.subplots(1, 2, figsize=(14, 4.8))
sns.scatterplot(data=df, x="Unidades", y="VentaTotal", hue="Producto", alpha=0.75, ax=ejes[0])
ejes[0].yaxis.set_major_formatter(mtick.FuncFormatter(millones)); ejes[0].set_title("Unidades frente a ingreso por transac
```

```
sns.scatterplot(data=df, x="PrecioUnitario", y="VentaTotal", hue="Producto", alpha=0.75, ax=ejes[1], legend=False)
ejes[1].xaxis.set_major_formatter(mtick.FuncFormatter(millones)); ejes[1].yaxis.set_major_formatter(mtick.FuncFormatter(mi
ejes[1].set_title("Precio unitario frente a ingreso por transacción")
plt.tight_layout(); plt.show()
```



Interpretación.

- **Precio y venta total:** correlación fuerte (Pearson 0,84; Spearman 0,82). El ingreso de una transacción depende sobre todo del precio del producto.
- **Unidades y venta total:** relación positiva pero moderada (Pearson 0,29; Spearman 0,51): vender más unidades ayuda, pero pesa mucho menos que el producto vendido.
- **Unidades y precio:** prácticamente nula (−0,02): no se compran más unidades de productos baratos ni menos de caros; la cantidad es independiente del precio.
- En el gráfico de dispersión se aprecian **bandas horizontales por producto**: dentro de cada producto el ingreso crece con las unidades, pero las bandas están separadas por el precio.

Nota: una correlación describe asociación, no causalidad.

Hallazgos principales

Gemini

```
# Aseguramos que las variables necesarias existan recreándolas si es necesar
if 'prod' not in globals():
    prod = resumen_dimension("Producto")
if 'reg' not in globals():
    reg = resumen_dimension("Region")
if 'ven' not in globals():
    ven = resumen_dimension("Vendedor")
if 'mensual' not in globals():
    mensual = df.groupby("Periodo")["VentaTotal"].sum().to_frame("VentaTotal
if 'tot' not in globals():
    semestre = df[df["Mes"] <= 6]
    comp = semestre.pivot_table(index="Mes", columns="Anio", values="VentaTo
    tot = comp.sum()

total = df["VentaTotal"].sum()
print("INDICADORES CLAVE")
print(f"· Ventas totales: ${total:,.0f} en {len(df)} transacciones ({df['Fec
print(f"· Ticket promedio: ${df['VentaTotal'].mean():,.0f}  |  Ticket median
print(f"· Producto líder: {prod.index[0]} ({prod['Participación %'].iloc[0]:
print(f"· Región líder: {reg.index[0]} ({reg['Participación %'].iloc[0]:.1f}
print(f"· Vendedor líder: {ven.index[0]} ({ven['Participación %'].iloc[0]:.1
print(f"· Promedio mensual: ${mensual['VentaTotal'].mean():,.0f}")
print(f"· Variación interanual del primer semestre: {(tot[2026]/tot[2025]-1)
```

```
INDICADORES CLAVE
· Ventas totales: $1,917,355,000 en 414 transacciones (Jan 2025 – Jun 2026)
· Ticket promedio: $4,631,292  |  Ticket mediano: $1,335,000
· Producto líder: Laptop (63.7 % de las ventas)
· Región líder: Barranquilla (25.1 %)  |  Región con menor venta: Bogotá (9.9 %)
· Vendedor líder: Diana Gómez (23.2 %)
· Promedio mensual: $106,519,722
· Variación interanual del primer semestre: +8.0%
```

1. **Las ventas suman $1.917,4 millones * *en 18 meses (414 transacciones), con un ticket promedio de 4,63 millones y un ticket mediano de $1,34 millones.

2. **Hay una fuerte concentración en un producto:** las laptops generan el 63,7 % de los ingresos con el 14,3 % de las transacciones, y tres productos suman el 89 %.
3. **La distribución del ingreso es muy asimétrica** (asimetría 2,77; coeficiente de variación 1,73): 42 transacciones atípicas, todas de laptops, explican el 56,8 % de los ingresos.
4. **Número de transacciones y valor vendido no coinciden:** Sofía Reyes cierra más ventas (79) pero factura menos (12,5 %); Diana Gómez lidera en ingresos (23,2 %) con 72 transacciones.
5. **Barranquilla es la región líder (25,1 %) y Bogotá la de menores ventas (9,9 %)**; la diferencia se explica sobre todo por las laptops.
6. **La evolución mensual es volátil** y depende de las laptops (correlación de 0,90 entre las ventas mensuales totales y las de laptops).
7. **El primer semestre de 2026 creció 8,0 %** frente a 2025, pero el crecimiento se concentra en el primer trimestre (+60,7 %): el **segundo trimestre cayó 19,5 %**. Crecieron las impresoras y las laptops; los accesorios cayeron entre −22 % y −39 %, y **Pereira cayó −68,8 %**.
8. **Los precios no cambiaron** (variaciones entre −1,3 % y +0,9 %): el crecimiento viene del volumen y de la mezcla de productos.